

État d'avancement — Projet MLOps

Versioning des données et pipeline DVC

Prediction de l'Espérance de Vie – Modélisation Machine Learning & EDA & MLOps

1. Objectif actuel

Construire progressivement un pipeline MLOps reproductible. DVC décrit les dépendances entre les données, le code de traitement et les fichiers produits par chaque étape.

2. Éléments actuellement utilisés

- data/rows/01_dataset.csv — dataset source
- src/preprocessing_data.py — code de preprocessing
- src/processed/ — fichiers produits
- dvc.yaml — définition du pipeline DVC

3. Stage DVC créé

Le stage actuel est :


```
uv run dvc stage add -n preprocessing_data -d data/rows/01_dataset.csv -o
src/processed/test_df_x.csv -o src/processed/train_df_x.csv -o
src/processed/test_df_y.csv -o src/processed/train_df_y.csv python
src/preprocessing_data.py
```

4. Fonctionnement du stage

Le stage preprocessing_data prend le dataset brut, exécute le script de preprocessing et produit quatre fichiers préparés.

- Entrée : data/rows/01_dataset.csv
- Script : src/preprocessing_data.py
- Sortie : src/processed/test_df_x.csv
- Sortie : src/processed/train_df_x.csv
- Sortie : src/processed/test_df_y.csv
- Sortie : src/processed/train_df_y.csv

5. Flux actuel



```
train_df_x.csv / test_df_x.csv
train_df_y.csv / test_df_y.csv
```

6. Dépendances DVC

La dépendance actuelle déclarée est le dataset. Il est recommandé de déclarer également le script de preprocessing afin que DVC sache que la modification du code doit invalider le stage.

deps:

- data/rows/01_dataset.csv
- src/preprocessing_data.py

7. Reproduction du pipeline


DVC ne relance pas automatiquement le pipeline dès qu'un fichier change. Il détecte les changements lorsqu'on exécute :

```
uv run dvc repro
```


Si le dataset ou le script de preprocessing change, le stage devient obsolète et est réexécuté. Si rien n'a changé, DVC peut ignorer le stage.


8. Ajout futur de nouvelles données

Si un deuxième dataset possède la même structure et doit être traité avec le même preprocessing, il n'est généralement pas nécessaire de créer un nouveau stage. Le code pourra charger les deux datasets et les concaténer, et les deux fichiers devront être déclarés comme dépendances dans dvc.yaml.



9. Architecture MLOps visée





10. Prochaine étape

Créer le stage `train_model`. Il prendra les données d'entraînement produites par le preprocessing comme dépendances et produira le modèle entraîné.

Flux : `preprocessing_data` → `train_model` → `evaluate_model` → MLflow

11. Commandes importantes

```
uv run dvc stage add ...      # créer un stage

uv run dvc repro              # reproduire le pipeline

git add dvc.yaml              # préparer la modification pour Git

git commit -m "Add preprocessing stage"
```

Le message indiquant que DVC n'a pas pu créer immédiatement `src/processed/.gitignore` n'empêche pas la création du stage : DVC a bien ajouté `preprocessing_data` dans `dvc.yaml`. Le `.gitignore` devra être vérifié avant de finaliser le versioning Git/DVC.